

MASTERCLASS EN DATA SCIENCE

Del análisis exploratorio al modelo en producción

Vanessa Moscardó

· 09 Septiembre 2026 ·

Vanessa Moscardó



EXPERTISE FIELD

- data analysis and proccessing,
- Data modelling,
- AI, Machine Learning, Generative AI

- PhD in Computer Scince
- Senior Researcher in the Universidad Internacional de Valencia (VIU)
 - *Research Group: GREENIUS* (<https://greeniusviu.com/>)
- Director of the Data Science and Artificial Ingelligence Degree in VIU
- Associate Professor in Universitat Politècnica de Valencia (UPV)
- Collaboration and working as Researcher and IA engineer in Private Company: **Itify** (<https://itify.pro/es>)



Universidad
Internacional
de Valencia





RESEARCH / ACADEMIA



IA, modelos de predicción,
Algoritmos de control
(aplicado a Salud)

PhD – UPV
(2019)



IA aplicada a Salud y
sostenibilidad,
PLN

Senior Researcher – VIU



LLM fundamentos,
LLM y RL aplicado
al Trading
IA aplicada a Salud y
sostenibilidad,
PLN

Senior Researcher – VIU

Directora Grado de Ciencia
de Datos e IA



HOY



ENTORNO EMPRESARIAL



IA, modelos de predicción
Aplicada a las
telecomunicaciones

Kenmei Technologies



IA y PLN en
proyectos de Salud,
Aseguradoras, ...

Tyris Software



LLM y
IA Agéntica

Maisa



LLM,
IA Runtime Layer
(ReIAI)

Itify Solutions
(IA Lab)



HOY

Vanessa Moscardó



EXPERTISE FIELD

- data analysis and proccessing,
- Data modelling,
- AI, Machine Learning, Generative AI

CONTACTO



www.linkedin.com/in/vanessa-moscardó-garcia



vmoscardo@universidadviu.com // Vanessa@itify.pro

Contenidos

01

Contexto y Fundamentos

KDD · CRISP-DM · El DS en 2026

02

Datos: EDA & Feature Engineering

Análisis exploratorio · Transformaciones

03

Modelado Robusto

Gradient Boosting · Validación · Hyperparameters

04

Explicabilidad / XAI

SHAP · LIME · PDP · ICE

05


Del modelo a producción

MLOps · MLflow · Data Drift

1. Contexto y Fundamentos

El Data Scientist en 2026 · El problema antes del modelo · KDD y CRISP-DM


Un rol que ha madurado



Competencias clave

- Dominio estadístico: probabilidad, inferencia, álgebra lineal
- Ingeniería de software: código limpio, versioning, APIs
- Conocimiento del dominio y visión de negocio
- Comunicación: traducir resultados a decisiones
- MLOps: desplegar y mantener modelos en producción

Un rol que ha madurado



Competencias clave

- Dominio estadístico: probabilidad, inferencia, álgebra lineal
- Ingeniería de software: código limpio, versioning, APIs
- Conocimiento del dominio y visión de negocio
- Comunicación: traducir resultados a decisiones
- MLOps: desplegar y mantener modelos en producción

Por qué fracasan los proyectos de Data Science

Bloque 1

Gartner: 80-87% de los proyectos de ML/AI no llegan a producción

Problema mal formulado

El equipo modela algo diferente a lo que necesita el negocio

Sin infraestructura

El modelo existe en un notebook pero no puede desplegarse

Calidad de datos

Datos incompletos, sesgados o no representativos

Distributional Shift

Datos en producción distintos a los de entrenamiento

Data Leakage

El modelo aprende con información no disponible en producción

Falta de adopción

El negocio no confía ni entiende el modelo

La formulación correcta del problema es el paso más crítico

- 1 ¿Qué decisión tomará el negocio con los resultados del modelo?
- 2 ¿Qué output necesita: probabilidad, categoría, valor numérico, ranking?
- 3 ¿Cuál es el coste del error? ¿Es peor un FP o un FN?
- 4 ¿Con qué frecuencia se usará? ¿Tiempo real o batch?
- 5 ¿Qué datos estarán disponibles en el momento de la predicción?

Accuracy ≠ Utilidad

Churn con 95% clase "no-churn": predecir siempre la clase mayoritaria → 95% accuracy, modelo inútil

AUC-ROC ≠ Operabilidad

Detección de fraude: excelente AUC pero 10.000 falsas alarmas diarias que el equipo no puede gestionar

Precisión ≠ Valor

Recomendación: alta precisión pero items que el usuario ya conoce → sin valor añadido real

KDD (1996)

Fayyad, Piatetsky-Shapiro & Smyth · AI Magazine

1. Selección

2. Pre-procesamiento

3. Transformación

4. Data Mining

5. Interpretación / Evaluación

CRISP-DM (1999)

Daimler, SPSS, NCR, Ohra · Estándar industrial

Business
Understanding

Deployment

Data Understanding

↻ iterativo

Evaluation

Data Preparation

Modeling

KDD vs CRISP-DM — Comparativa

Bloque 1

Dimensión	KDD	CRISP-DM
Año	1996	1999
Origen	Académico (AI Magazine)	Industrial (Daimler, SPSS, NCR)
Enfoque	Data Mining como núcleo	Business Understanding como inicio
Flujo	Lineal / secuencial	Iterativo / cíclico
Orientación	Extracción de conocimiento	Valor de negocio
Uso actual	Base teórica	Referencia práctica dominante

Cómo se mapea CRISP-DM a esta masterclass

Bloque 1

Fase CRISP-DM

Business Understanding



Bloque de la Masterclass

Bloque 1

Data Understanding



Bloque 2 — EDA

Data Preparation



Bloque 2 — Feature Engineering

Modeling



Bloque 3 — Gradient Boosting

Evaluation



Bloque 3 — Validación

Deployment



Bloque 5 — MLOps

2. Datos: Calidad, EDA & Feature Engineering

Limpieza · Análisis exploratorio avanzado · Transformaciones · Selección de variables

GARBAGE IN, GARBAGE OUT

El mejor algoritmo no puede compensar datos de mala calidad

45–60%

del tiempo de un DS se invierte en
preparación de datos

Anaconda State of Data Science, 2022

80%

de proyectos de ML fallan por
problemas de datos, no de algoritmos

Gartner / IBM surveys

1:10

ratio coste de arreglar un error de
datos en prod vs. en origen

IBM Cost of Poor Data Quality

Un dataset de calidad debe satisfacer 6 dimensiones — una sola falla puede invalidar el análisis

Compleitud

¿Están presentes todos los registros y campos esperados? Los valores faltantes deben ser intencionados, no accidentales.

 `df.isnull().sum() / len(df)`

Exactitud

¿Los valores reflejan la realidad? Un valor puede estar presente pero ser incorrecto (edad=200, precio=-5€).

 Validación con rangos de dominio y fuentes externas

Consistencia

¿Los datos son coherentes entre sí y entre fuentes? Ej: fecha_nacimiento incompatible con fecha_contrato.

 Reglas de negocio cruzadas entre columnas

Actualidad

¿Los datos son suficientemente recientes para el problema? Datos de hace 5 años pueden ser irrelevantes hoy.

 Verificar timestamps y ventanas temporales del dataset

Unicidad

¿Hay registros duplicados? Los duplicados inflan métricas y sesgan el modelo, especialmente en train set.

 `df.duplicated().sum()` — considerar duplicados parciales

Validez

¿Los valores cumplen el formato y tipo esperado? Fechas como strings, categorías fuera del dominio definido.

 `df.dtypes` + validación con expresiones regulares

Estos pasos deben ejecutarse en orden antes de cualquier análisis exploratorio

1 Inspección inicial

- `df.shape, df.dtypes, df.head()` — estructura general
- `df.info()` — detecta nulos y tipos erróneos

```
df.info() # dtypes + non-null counts
df.describe(include='all')
```

2 Corrección de tipos y formatos

- Convertir fechas: `pd.to_datetime(df["fecha"])`
- Casting numérico: `pd.to_numeric(..., errors="coerce")`

```
df['fecha'] = pd.to_datetime(df['fecha'])
df['precio'] = pd.to_numeric(df['precio'],
                             errors='coerce')
```

3 Duplicados

- Duplicados exactos: `df.duplicated().sum()`
- Duplicados parciales: subconjunto de columnas clave

```
df.drop_duplicates(subset=['id_cliente'], keep='last')
```

4 Valores imposibles y fuera de rango

- Definir rangos válidos por columna con el dominio
- Reemplazar con NaN para tratamiento posterior

```
df.loc[df['edad'] > 120, 'edad'] = np.nan
df.loc[df['precio'] < 0, 'precio'] = np.nan
```

5 Estandarización de categorías

- `df["pais"].value_counts()` — detecta variantes
- Unificar: "España" = "spain" = "ES" = "SPAIN"

```
df['pais'] = df['pais'].str.strip().str.upper()
df['pais'].replace({'ESPAÑA': 'ES', 'SPAIN': 'ES'},
                   inplace=True)
```

6 Reporte de calidad y logging

- Documentar cada transformación aplicada
- Guardar el dataset limpio con versión (v1_clean.csv)

```
# great_expectations o pandas_profiling
ProfileReport(df_clean).to_file('report.html')
```

El EDA tiene un objetivo concreto: informar decisiones de modelado

Distribuciones univariantes

- Histogramas + KDE
- Q-Q plots para normalidad
- Boxplots para outliers IQR

Relaciones bivariantes

- Scatter plots + trend lines
- Heatmap de correlación (Pearson/Spearman)
- Cramér's V para categóricas

Datos faltantes (MCAR/MAR/MNAR)

- `msno.matrix()` + dendrograma
- Patrón de missingness sistemático
- Impacto en sesgo del modelo

Análisis multivariante

- PCA para reducción visual
- Pair plots (seaborn)
- Clustering exploratorio (k-means)

Outliers: identificación y tratamiento

- Regla del IQR: $Q1 - 1.5 \times IQR$, $Q3 + 1.5 \times IQR$
- Z-score: $|z| > 3$ (asume normalidad)
- Isolation Forest (multivariante)
- Opciones: eliminar · winsorizar · transformar (log)

PUNTO CRÍTICO

No elimines outliers automáticamente. En fraude, los outliers SON la señal. Comprender por qué existe un outlier es más importante que eliminarlo.

Missing Values: MCAR · MAR · MNAR

MCAR

Missing Completely At Random — no patrón → imputación segura

MAR

Missing At Random — depende de otras variables observadas → imputación con modelo

MNAR

Missing Not At Random — depende del propio valor → sesgo sistemático

Estrategias de imputación

- Media/mediana/moda (simple)
- KNN Imputer · IterativeImputer (MICE)
- Indicador binario "era nulo"

"En machine learning, más que el algoritmo, lo que marca la diferencia son las features." — Andrew Ng

Transformaciones Numéricas

- Log, sqrt, Box-Cox, Yeo-Johnson
- Binning: igual anchura vs. igual frecuencia
- Escalado: StandardScaler, MinMaxScaler, RobustScaler

Variables de Interacción

- Producto: $\text{precio} \times \text{cantidad} \rightarrow \text{revenue}$
- Ratio: $\text{deuda} / \text{activos} \rightarrow \text{leverage}$
- Diferencia temporal: hoy – último_evento

Encoding Categórico

- OHE: baja cardinalidad (<10 categorías)
- Label/Ordinal: categorías con orden
- Target Encoding: alta cardinalidad (con regularización)
- Frequency Encoding: cardinalidad muy alta

Features Temporales

- Extracción: año, mes, día, hora, weekday
- Lag features: valor de t-1, t-7, t-30
- Rolling stats: media móvil, max, std

Filter Methods

Independientes del modelo. Rápidos pero ignoran interacciones.

- Correlación de Pearson/Spearman
- Información mutua (mutual_info_classif)
- Chi² para variables categóricas
- Variance Threshold

Wrapper Methods

Usan el modelo para evaluar subconjuntos. Lentos pero precisos.

- RFE (Recursive Feature Elimination)
- Forward/Backward Selection
- Boruta (basado en RF)

Embedded Methods


La selección ocurre durante el entrenamiento del modelo.

- L1 (Lasso) regularization
- Feature importance de árboles
- SHAP importance

RECOMENDACIÓN PRÁCTICA

Empieza con filter methods para eliminar features irrelevantes (correlación > 0.95 entre sí o varianza ≈ 0), luego usa feature importance del modelo para una selección más fina.

El Pipeline garantiza que NO hay data leakage y que el preprocesamiento es idéntico en train y en producción



```
sklearn.pipeline.Pipeline([("prep", ct), ("sel", selector), ("model", xgb)])
```

ColumnTransformer — procesamiento diferenciado por tipo de variable:

Numérico: SimpleImputer(median) → RobustScaler → PolynomialFeatures(deg=2)

Categórico: SimpleImputer(most_frequent) → OrdinalEncoder / OneHotEncoder


Datetime: CustomTransformer (extrae año, mes, día, weekday, lag features)

3. Modelado Robusto y Selección

Selección del modelo · Validación · Optimización de Hiperparámetros

Selección del modelo — Algoritmos basados en IA

Ramas de la Inteligencia artificial



Machine Learning

Es el campo base de la IA, en el que las máquinas aprenden a identificar patrones en los datos para hacer predicciones o clasificaciones.



Deep Learning

Es una subdisciplina del ML, enfocada en algoritmos que simulan el funcionamiento del cerebro humano para resolver problemas complejos.


IA Generativa

Es una rama de la IA que crea contenido nuevo a partir de datos existentes, como imágenes, texto o música. Basadas en redes neuronales profundas.

Selección del modelo — Machine Learning



Selección del modelo — Machine Learning



Aprendizaje Supervisado

Datos etiquetados

Regresión

- Predicción de demanda de insulina en base a los CHO

Árboles de decisión

- Estimación del estadio de diabetes T2 en base a diferentes factores

Clustering

- Determinación de distintos grupos de pacientes dadas unas características en común

Aprendizaje No Supervisado


Datos etiquetados

Reducción de la dimensionalidad

- Reducción de variables en análisis que nos son relevantes para modelo

Minería de reglas

- (Asociación o clasificación)*
- Determinar zonas de riesgo del paciente en base a umbrales de glucosa



Selección del modelo — Aprendizaje por Refuerzo

Aprendizaje por Refuerzo

Aprendizaje por refuerzo


Acción – recompensa - Penalización

RL basado en modelos

- Gemelos digitales para optimizar la inyección de insulina y glucagón


RL sin modelo

- Recomendaciones personalizadas del bolo de insulina.




Selección del modelo — Deep Learning

Deep Learning



Subárea de Machine Learning que utiliza **redes neuronales** profundas con múltiples capas para aprender automáticamente representaciones complejas de los datos



Percepción Multicapa (MLP)

- Predicción prefill de glucosa

Redes Convolucionales (CNN)

- Diagnóstico por Imagen Médica

Redes Recurrentes (RNN)

- Chatbots de Atención al paciente.

Autoencoders


- Detección de anomalías e los registros de glucosa

Transformers

- Traducción Automática
- Análisis del estado de ánimo del paciente

Selección del modelo — IA Generativa

IA Generativa




La **IA generativa** es aquella rama de la inteligencia artificial que permite producir contenidos originales –como **texto, imágenes, vídeo, audio o incluso código**– en respuesta a instrucciones o "**prompts**" de un usuario. Se apoya en modelos de **deep learning** que, al entrenarse con **enormes cantidades de datos**, aprenden a identificar patrones y estructuras para luego generar nuevo contenido que imita (o se basa en) esos mismos patrones.

Large Language Models (LLM)



¿Por qué Gradient Boosting presenta buenos resultados en los proyectos industriales?

Idea central: aprendizaje aditivo de errores residuales



Cada árbol $h_i(x)$ aprende los residuos del modelo anterior usando el gradiente de la función de pérdida

XGBoost (2014)	LightGBM (2017)	CatBoost (2017)
Regularización L1+L2 · Pruning · Parallel tree	GOSS + EFB · Leaf-wise growth · Muy rápido	Ordered boosting · Target stat nativa · Sin encoding manual

Hiperparámetros Clave — XGBoost & LightGBM

Bloque 3

Hiperparámetro	Rango típico	Descripción	Impacto
<code>n_estimators</code>	100–3000	Número de árboles. Cuanto más, mejor (hasta overfitting). Usar early stopping.	alto
<code>max_depth</code>	3–10	Profundidad máx del árbol. Controla complejidad. LightGBM: <code>num_leaves</code> en su lugar.	alto
<code>learning_rate</code> (η)	0.01–0.3	Contracción por árbol. Bajo $\eta \rightarrow$ más árboles necesarios $\rightarrow$ mejor generalización.	alto
<code>subsample</code>	0.6–0.9	Fracción de filas por árbol. Reduce overfitting y acelera entrenamiento.	medio
<code>colsample_bytree</code>	0.5–0.9	Fracción de columnas por árbol. Similar al random forest feature sampling.	medio
<code>min_child_weight</code>	1–20	Peso mínimo de hoja. Regularización. Aumentar si dataset pequeño o ruidoso.	medio
<code>reg_alpha</code> / <code>reg_lambda</code>	0–10	Regularización L1/L2. <code>reg_lambda</code> (L2) por defecto=1. <code>reg_alpha</code> (L1) $\rightarrow$ sparsity.	bajo



Grid Search

✓ Exhaustivo, reproducible

✗ Exponencialmente lento (maldición dimensionalidad)



Random Search

✓ 30x más eficiente que Grid.
Cobertura uniforme del espacio

✗ No aprende de iteraciones anteriores



Bayesian Opt. (Optuna)

✓ RECOMENDADO

✓ Aprende qué regiones son prometedoras. Más eficiente.

✗ Requiere más configuración inicial

La elección de la estrategia de validación es tan importante como la elección del modelo

K-Fold CV

Cuándo: Dataset IID, clasificación/regresión estándar

```
KFold(n_splits=5, shuffle=True)
```

Stratified K-Fold

Cuándo: Clasificación con clases desbalanceadas (mantiene la proporción)

```
StratifiedKFold(n_splits=5)
```

TimeSeriesSplit

Cuándo: Datos temporales — NUNCA usar KFold estándar

```
TimeSeriesSplit(n_splits=5)
```

Group K-Fold

Cuándo: Cuando los datos tienen grupos (pacientes, tiendas)

```
GroupKFold(n_splits=5)
```

Clasificación

Accuracy Clases balanceadas $(TP+TN) / (P+N)$

Precision Coste FP alto (spam, fraude) $TP / (TP+FP)$

Recall Coste FN alto (cáncer, churn) $TP / (TP+FN)$

F1-Score Equilibrio P/R, desbalance $2 \cdot P \cdot R / (P+R)$

AUC-ROC Ranking de probabilidades
Área bajo curva ROC

PR-AUC Clases muy desbalanceadas
Área bajo curva PR

Regresión

MAE Fácil interpretación $\text{mean} | y - \hat{y} |$

RMSE Penaliza errores grandes $\sqrt{\text{mean} (y - \hat{y})^2}$

MAPE Interpretabilidad % $\text{mean} | y - \hat{y} | / | y |$

R² Proporción varianza explicada $1 - SS_{\text{res}} / SS_{\text{tot}}$

⚠ PUNTO CRÍTICO

Escoger la métrica/métricas óptimas alineadas con el objetivo o problema a resolver

4. Explicabilidad e Interpretabilidad

XAI · SHAP · LIME · PDP · ICE

Taxonomía de Interpretabilidad

Intrínseco

El modelo es interpretable por diseño

Ej: Regresión lineal, árbol de decisión, reglas if-then

Post-hoc

Explicamos un modelo ya entrenado

Ej: SHAP, LIME, PDPX, Integrated Gradients

Global

¿Cómo funciona el modelo en general?

Ej: Feature importance, SHAP summary plots, PDP

Local

¿Por qué esta predicción concreta?

Ej: LIME, SHAP force plot, counterfactuals

Lundberg & Lee, NeurIPS 2017 · El estándar de facto para explicabilidad en 2026

Los valores SHAP son la contribución marginal de cada feature a la predicción, promediada sobre todos los posibles subconjuntos de features. Tienen base teórica en la teoría de juegos cooperativos (Shapley, 1953). Para cualquier predicción: $f(x) = \text{baseline} + \sum \phi_i(x_i)$

Summary Plot

Importancia global. Cada punto = una muestra. Color = valor de la feature. Posición X = impacto en la predicción.

Force Plot

Explicación local. Muestra por qué el modelo predijo X para esta observación concreta. Features que suman vs. restan.

Dependence Plot

Relación entre el valor de una feature y su SHAP value. Revela no-linealidades e interacciones.

Decision Plot

Traza cómo la predicción se acumula feature a feature. Útil para diagnóstico de casos individuales.

LIME — Local Interpretable Model-agnostic Explanations (Ribeiro et al., 2016)

Perturba el entorno local de la instancia → entrena un modelo simple (lineal) en esas perturbaciones → los coeficientes del modelo simple son la explicación local. Ventaja: model-agnostic. Desventaja: inestable — puede dar explicaciones distintas para la misma instancia.

PDP — Partial Dependence Plot

Efecto marginal PROMEDIO de una feature sobre la predicción. Asume independencia entre features (limitación). Identifica relaciones no lineales globales. Útil: ¿cómo cambia la predicción media al variar "edad" de 20 a 80?

ICE — Individual Conditional Expectation

Como PDP pero para cada observación individual. Revela heterogeneidad: si las curvas ICE son paralelas → sin interacción. Si se cruzan → interacción importante. PDP = media de todas las curvas ICE.


CUÁNDO USAR CADA UNA

SHAP: primera opción siempre (global + local, rápido en GBMs).
LIME: cuando SHAP no está disponible o el modelo es muy black-box.
PDP: comunicar efecto de una variable al negocio.
ICE: detectar heterogeneidad e interacciones.

5. Del modelo a producción — MLOps

MLflow · Monitoring · Data Drift · Concept Drift

"Un modelo que no está en producción no genera valor. Un modelo en producción sin monitoring genera riesgo."



MLflow — 4 componentes clave

Tracking: `log_metric`, `log_param`, `log_artifact` en cada experimento.

Model Registry: versioning, staging (Staging → Production → Archived).

Projects: empaquetar código reproducible.

Models: serving con `mlflow models serve --model-uri`.

Data Drift y Concept Drift — Por qué los modelos se degradan

Bloque 5

Data Drift (Covariate Shift)

La distribución de las features X cambia, pero la relación $P(Y|X)$ se mantiene.

Detección: PSI (Population Stability Index), KS test, Jensen-Shannon divergence

El perfil demográfico de los clientes cambia con el tiempo.

Concept Drift (Label Drift)

La relación $P(Y|X)$ cambia. El mismo input ahora debería producir un output diferente.

Detección: Monitor métricas del modelo en producción. Requiere ground truth con retardo.

Comportamiento de fraude evoluciona y el modelo antiguo no lo detecta.

Prior Probability Shift

La distribución de la variable objetivo $P(Y)$ cambia.

Detección: Monitorizar distribución de predicciones y scores de salida.

La prevalencia de una enfermedad aumenta durante una pandemia.

Conclusiones

- 01 Formula el problema antes de abrir un dataset. El 80% de los fracasos ocurren aquí.
- 02 El EDA no es un trámite — es investigación activa que guía TODAS las decisiones de modelado.
- 03 El Feature Engineering marca más la diferencia que el algoritmo elegido.
- 04 Validación robusta primero, métricas alineadas con el negocio siempre.
- 05 SHAP hace explicables incluso los modelos más complejos. XAI no es opcional.
- 06 Un modelo sin monitoring en producción es una bomba de tiempo.

¡Muchas gracias! · Preguntas

¡Muchas gracias!

¿Dudas, Preguntas?

